## Lezione 05

Abbiamo trovato  $lpha_{opt}$  per Richardson stazionario e dinamico. Nel caso dinamico precondizionato:

$$lpha_k = rac{[z^{(k)}]^T r^{(k)}}{[z^{(k)}]^T A z^{(k)}}$$

# Ciclo di Implementazione di Richardson

Prendendo come valori iniziali:

- $x^{(0)}$
- Tollerenza
- Numero massimo di iterazioni
- Restante iniziale

per k da 0,1,..., $N_{max}$ 

I quattro passi dell'algoritmo sono:

- 1.  $Pz^{(k)} = r^{(k)} o$  Ricavo  $z^{(k)} o$  facciamo la fattorizzazione LU 1 volta
- 2.  $\alpha_k$  = (quello che abbiamo visto prima)
- 3.  $x^{(k+1)} = x^{(k)} + \alpha_k z^{(k)}$

4. 
$$r^{(k+1)} = b - Ax^{(k+1)} = b - A(x^{(k)} - \alpha_k z^{(k)}) = \underbrace{b - Ax^{(k)}}_{(k)} - \alpha_k Az^{(k)} = r^{(k)} - \alpha_k Az^{(k)}$$

Questi 4 passi sono con per con il metodo del gradiente precondizionato, nel caso del gradiente non precondizionato il primo passo è inutile, quindi sono 3 passi.

Per Richardson stazionario precondizionato servono 3 passi, perché il primo passo è inutile. Invece, nel caso non precondizionato, servono solo 2 passi perché il passo 1 e 2 sono inutili.

## Metodo del Gradiente Coniugato

Non ci chiederà mai di fare il metodo del gradiente coniugato, ci chiede solo di capire perché è più veloce il fatto che è più veloce.

Partiamo dalla modalità non precondizionata, richiedendo che A sia sdp, se non lo è ci sono latri algoritmi.

Prendiamo  $\{p^{(k)}\}$  come le direzione a coniugate, dove per ogni  $p^{(k)}$  troviamo che è A-ortogonale ad ogni altra  $p^{(k)}$ . La A-ortogonalità è quando:

$$[p^{(i)}]^T p^{(j)} = 0 o ext{Ortogonolità normale} \ [Ap^{(i)}]^T p^{(j)} = 0 o ext{A-Ortogonalità} \ [p^{(i)}]^T A^T p^{(j)} = 0 \ \ orall i 
ota j$$

Le condizioni iniziali sono:

- $x^{(0)} \to r^{(0)}$
- $p(0) = r^{(0)}$

Il ciclo dell'algoritmo è:

$$\begin{aligned} &1. \ \widetilde{\alpha}_k = \frac{[p^{(k)}]^T r^{(k)}}{[p^{(k)}]^T A p^{(k)}} \\ &2. \ x^{(k+1)} = x^{(k)} + \widetilde{\alpha}_k p^{(k)} \\ &3. \ r^{(k+1)} = r^{(k)} - \widetilde{\alpha}_k A p^{(k)} \\ &4. \ \beta_k = \frac{[A p^{(k)}]^T r^{(k+1)}}{[A p^{(k)}]^T p^{(k)}} \\ &5. \ p^{(k+1)} = r^{(k+1)} - \beta_k p^{(k)} \end{aligned}$$

Prima definevamo  $r^{(k)}$  come ortogonali solo con quello prima e quello dopo, ora definiamo che ogni  $p^{(k)}$  sia A-ortogonale con ogni altro.

Visto che Q parabolico può esser ellittica in sezione, l'aggiunta di A rende la sezione più circolare, riducendo il numero di passi necessari per arrivare al minimo del paraboloide, perché ci servono meno zig-zag.

L'errore di questo metodo sarà:

$$|e^{(k)}|_A \leq \left(rac{K(P^{-1}A)-1}{K(P^{-1}A)+1}
ight)^k |e^{(0)}|_A$$

Se P=I allora per il non-coniugato il fattore di convergenza è funzione di K(A) solamente. Con il coniugato invece sarà funzione di  $\sqrt{K(A)}$ , questa differenza non è in-significativa, rendendo l'algoritmo molto più veloce.

In casi specifici è possibile che converga in n(dimensione del sistema) passi.

Con il precondizionatore la velocità aumenta ancora di più.

## Definizione di K(A)

Per il sistema Ax = b usando il metodo diretto di LU+pivoting, PA-LU = 0.

Sappiamo che LU è accurata, questo implica che x anche lei è accurata? No, se il problema è malcondizionato allora la matrice x non sarà accurata.

Possiamo usare il numero di condizionamento K(A) per determinare prima che iniziamo a fare il ciclo, per vedere se il problema è malcondizionato o no.

Se K(A) ha valore basso, allora è ben condizionato, invece se è molto grande lo consideriamo come mal condizionato.

## Esempio di matrice malcondizionata

Prendiamo n crescente e definiamo il sistema:

$$A_n \in \mathbb{R}^{n imes n} o A_n x_n = b_n$$

Dove  $A_n$  sarà la matrice:

$$\begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \dots \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \dots \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

Cioè ogni elemento è  $a_{ij}=rac{1}{i+j+1}$ 

 $b_n$  sarà il fattore che da soluzione  $x_n = [1, \dots, 1]^T$   $ilde{x_n}$  sarà la soluzione ricavata.

In un mondo ideale, l'errore con il metodo della fattorizzazione dovrebbe esser 0 per ogni elemento.

Se controlliamo in base all'accuratezza, con l'equazione:

$$E_n = rac{|x_n - ilde{x}_n|}{|x_n|}$$

Mappando l'errore massimo per elemento e questo errore di accuratezza in base alla dimensione del sistema troviamo che:

Per n  $\geq 13$ , l'errore di accuratezza sarà  $\geq 10$ , cioè un errore del 1000%.

La matrice di Hilbert (quella che stiamo guardando) da un errore immenso con i metodi diretti. Perche?

#### Il perché

Quando scriviamo Ax=b

Quello che stiamo scrivendo veramente è:

$$(A + \delta A)(x + \delta x) = (b + \delta b)$$

Dove  $\delta A \in \mathbb{R}^{n imes n}$  e  $\delta b \in \mathbb{R}^n$ , sono perturbazioni per varie ragioni come l'errore floating point.

Se  $\delta A$  e  $\delta b$  sono piccole allora anche  $\delta x \in \mathbb{R}^n$  sono piccole, con la matrice di Hilbert questi errori sono particolarmente grandi.

Vogliamo capire la relazione tra le perturbazioni:

$$rac{|\delta A|}{|A|},rac{|\delta b|}{|b|}
ightarrowrac{|\delta x|}{|x|}$$

Prendendo  $\delta A=0$  c'è la relazione  $rac{|\delta x|}{|x|}\leq K(A)rac{|\delta b|}{|b|}$ 

 $K(A) \geq 1$ , sempre.

Se K(A) = 3, va bene, invece se K(A) =  $10^5$  va male.

Il rapporto tra le perturbazioni rimane simile quindi va bene.

Quando K(A) è basso agisce come fattore di contenimento, invece quando è altro agisce come amplificatore dell'errore.

Nel caso di Hilbert  $K(A_n)$  aumenta più n $ightarrow \infty$ 

## Calcolo di K(A)

Nel modo più semplice:

$$K(A) = |A||A^{-1}|$$

#### Diverse norme di matrici

La norma tipo 1 di una matrice equazione:

$$|A|_1 = max_j \left(\sum_{i=1}^n |a_{ij}|
ight)$$

Cioè e il massimo delle somma assolute di ogni colonna.

La norma tipo  $\infty$  di una matrice equazione:

$$|A|_{\infty} = max_i \left( \sum_{j=1}^n |a_{ij}| 
ight)$$

Cioè e il massimo delle somma assolute di ogni colonna.

Ogni norma di matrice genera il suo valore K(A), cioè:

$$K_1(A) = |A|_1 |A^{-1}|_1 \ K_2(A) = |A|_2 |A^{-1}|_2 \ K_\infty(A) = |A|_\infty |A^{-1}|_\infty$$

Tutti questi valori sono connessi tra l'un l'altro, se uno indica che il sistema è mal condizionato anche il resto lo indica.

Se A è sdp:  $|A|_2=\lambda_{max}(A)$  e  $|A^{-1}|_2=\frac{1}{\lambda_{min}(A)}$ , questo allora significa che il valore di condizionamento sarà:

$$K_2(A) = rac{\lambda_{max}(A)}{\lambda_{min}(A)}$$

Invece come abbiamo visto nella prima lezione se A non è sdp, allora:

$$K_2(A) = \sqrt{rac{\lambda_{max}(A^TA)}{\lambda_{min}(A^TA)}}$$

# Caso generale, $\delta A \neq 0$

Tale che il determinatore sia strettametne positivo, prendiamo:  $|\delta A||A^{-1}| < 1$ 

La relazione sarà:

$$rac{|\delta x|}{|x|} \leq rac{K(A)}{1-K(A)rac{|\delta A|}{|A|}}igg(rac{|\delta b|}{|b|}+rac{|\delta A|}{|A|}igg)$$

## Ritorno a commentare la stima della convergenza

Ritorniamo a commentare la stima della convergenza che abbiamo detto ha valore:

$$|e^{(k)}|_A \le \left\lceil rac{K(P^{-1}A) - 1}{K(P^{-1}A) + 1} 
ight
ceil^k |e^{(0)}|_A$$

Finora, i requisiti che abbiamo posto su P sono che sia invertibile e "facile". Il nuovo requisito per P è che:

$$K(P^{-1}A) \ll K(A)$$

Cioè che P agisca prima del condizionatore (precondizionare) per ridurre il numero di condizionamento, riducendo il numero di iterazioni che ci servono.

Sappiamo che  $K(A) \geq 1$ , idealmente allora  $P^{-1} = A$ . Per ridurre il numero di iterazioni il più possibile, P deve esser il più vicino possibile all'inversa di A.

## Tornando al problema di Hilbert

Se calcoliamo il numero di iterazioni per ogni metodi visto in base alle dimensione del sistema troviamo la tabella:

#### **Stimatori**

Quando attivo un schema iterativo una condizione di arresto sarà:

$$|e^{(k)}| < S < TOL$$

Ci sono due stimatori usati generalmente, il primo è il residuo relativo che ha equazione:

$$rac{|r^{(k)}|}{|b|}=S_1$$

Se 
$$x^{(0)}=0$$
 allora  $r^{(k)}=b-Ax^{(0)}=b$ 

Il secondo stimatore è l'incremento tra iterazioni:

$$S_2 = |x^{(k+1)} - x^{(k)}|$$

Questo è assoluto, rispetto al primo che era relativo.